

Prédiction de séries temporelles appliquée aux indicateurs financiers

Rapport de Hackathon

Louis CLUZEL (M1 IA)

Arthur CLAVEAU (M1 STD) • Léo CHARBONNIER (M1 STD)

Mai 2026

Table des matières

Résumé exécutif	3
1 Introduction et Contexte	4
1.1 Cadre du hackathon	4
1.2 Objectifs	4
1.3 Actifs et indicateurs sélectionnés	4
2 État de l’Art	6
2.1 Modèles statistiques pour séries temporelles financières	6
2.2 Machine Learning pour la finance	6
2.3 Deep Learning pour les séries temporelles	7
2.4 Positionnement de notre étude	7
3 Méthodologie	8
3.1 Pipeline expérimentale	8
3.2 Données et prétraitement	9
3.3 Définition des régimes de marché	9
3.4 Matrice expérimentale	10
3.5 Modèles évalués	10
3.6 Métriques d’évaluation	11
3.6.1 Métriques individuelles	11
3.6.2 Score Hackathon	11
4 Résultats	13
4.1 Analyse par régime de marché	14
4.1.1 Hiérarchie de prévisibilité des régimes	14
4.1.2 Variabilité inter-régimes d’un même modèle	14
4.1.3 Argument pour la stratification par régime	15
4.2 Vue d’ensemble des scores hackathon	15
4.2.1 Configurations dépassant le seuil $S \geq 0,30$	15
4.2.2 Classement global par robustesse moyenne	16
4.2.3 Le paradoxe robustesse/performance de pointe	17
4.3 Focus : Bull Market pré-COVID (2017–2020)	17
4.3.1 Analyse par actif	18

4.3.2	Analyse par granularité temporelle	20
4.3.3	Comparaison par famille algorithmique	20
4.3.4	Heatmaps et visualisations par actif	21
5	Discussion	23
5.1	Pourquoi le MACD est-il plus facile à prédire que le Stochastique ?	23
5.2	Pourquoi le Bull Market pré-COVID est-il le régime le plus prévisible ? . .	24
5.3	Pourquoi le Deep Learning sous-performe sur séries courtes ?	24
5.4	Implications pour la finance quantitative	25
5.4.1	Il n'existe pas de modèle universellement optimal	25
5.4.2	La granularité comme filtre de bruit	25
6	Limites, Perspectives et Conclusion	26
6.1	Limites de l'étude	26
6.2	Pistes de recherche futures	26
6.3	Conclusion	27
7	Annexes	28
.1	Glossaire des termes techniques	28
.2	Scores hackathon complets (toutes configurations)	28
	Références bibliographiques	30

Résumé exécutif

Ce rapport présente les résultats d’une étude expérimentale comparative portant sur la prédiction de deux indicateurs d’analyse technique boursière — le **MACD** et l’**Oscillateur Stochastique** — appliquée à trois actifs majeurs du marché technologique américain (AAPL, MSFT, NVDA) sur cinq régimes de marché distincts.

Huit familles de modèles ont été évaluées : trois modèles statistiques classiques (ARIMA, SARIMA, Holt-Winters), deux modèles de machine learning (Random Forest, SVR) et trois architectures deep learning (LSTM, GRU, Transformer). La matrice expérimentale totalise **60 configurations** (3 actifs $\times$ 2 horizons temporels $\times$ 5 périodes $\times$ 2 indicateurs).

Les résultats sont évalués via un score hackathon composite :

$$S = \frac{T_{\text{MACD}} + \max(0, \rho_{\text{MACD}}) + T_{\text{Stoch}} + \max(0, \rho_{\text{Stoch}})}{4} \quad (1)$$

où T désigne la *Trend Accuracy* (précision directionnelle) et ρ le coefficient de corrélation de Pearson.

Principales conclusions :

- Une majorité des configurations (56%) franchissent le seuil de performance $S \geq 0,30$, avec une domination marquée des configurations hebdomadaires (*weekly*) parmi les plus performantes.
- Le meilleur score global est obtenu par **SARIMA sur NVDA** (Bull Market pré-COVID, weekly) : $S = 0,6246$.
- En robustesse moyenne, les modèles de **Machine Learning** (Random Forest : 0,358 ; SVR : 0,351) dominent, malgré l’absence de pic individuel au-dessus de 0,55.
- Le **MACD** est systématiquement mieux prédit que le Stochastique, quel que soit le modèle.
- Le **régime de marché** est le facteur le plus déterminant de la performance : l’écart entre le Bull Market (0,521) et la période Bear/Inflation (0,488) surpasse l’écart entre le meilleur et le pire modèle sur une même période.

Chapitre 1

Introduction et Contexte

1.1 Cadre du hackathon

Ce projet s'inscrit dans le cadre d'un hackathon académique dont l'objectif est de développer et d'évaluer des modèles de prédiction pour les indicateurs techniques financiers. Contrairement à la prédiction directe des prix, la prédiction d'indicateurs dérivés — comme le MACD et l'Oscillateur Stochastique — présente un intérêt particulier : ces signaux agrègent déjà de l'information sur la tendance et la dynamique du marché, mais restent intrinsèquement plus bruités et non-stationnaires que les prix bruts.

La problématique centrale est donc : *dans quelle mesure un modèle de machine learning ou de séries temporelles peut-il anticiper la direction future d'un indicateur technique, et cette capacité est-elle robuste aux différents régimes de marché ?*

1.2 Objectifs

1. Construire une matrice expérimentale couvrant 8 modèles, 3 actifs, 5 régimes de marché et 2 granularités temporelles.
2. Évaluer chaque configuration via le score composite hackathon S .
3. Identifier les facteurs de performance dominants (modèle, actif, régime, granularité).
4. Formuler des recommandations pour un déploiement en conditions réelles.

1.3 Actifs et indicateurs sélectionnés

Les trois actifs choisis représentent des profils de volatilité et de capitalisation très différents :

TABLE 1.1 – Caractéristiques des actifs analysés

Actif	Ticker	Secteur	Profil de volatilité
Apple Inc.	AAPL	Technologie grand public	Modéré, forte capitalisation
Microsoft Corp.	MSFT	Cloud/Logiciels	Stable, croissance régulière
Nvidia Corp.	NVDA	Semi-conducteurs / IA	Très élevé, forte tendance haussière

Les indicateurs calculés sont :

- **MACD(12,26,9)** : Moving Average Convergence Divergence. Différence entre deux moyennes mobiles exponentielles (12 et 26 périodes), lissée par une moyenne signal de 9 périodes. Capte la dynamique de tendance et les retournements de marché.
- **Stochastique(14,3,5)** : Oscillateur normalisé entre 0 et 100, mesurant la position du cours par rapport à son range récent. Identifie les zones de surachat/survente. Sa nature bornée et oscillante le rend fondamentalement plus difficile à prédire que le MACD.

Chapitre 2

État de l'Art

2.1 Modèles statistiques pour séries temporelles financières

Les modèles **ARIMA** (Auto-Regressive Integrated Moving Average), formalisés par Box et Jenkins (1970) [1], constituent la référence historique de la modélisation des séries temporelles. Leur principe repose sur la combinaison de composantes auto-régressives (AR), de différenciation (I) et de moyenne mobile (MA). Ils restent compétitifs pour la prévision à court horizon sur des séries stationnaires ou rendues stationnaires par différenciation.

Le modèle **SARIMA** [1] étend ARIMA en ajoutant une composante saisonnière $(P, D, Q)_s$, adaptée aux séries présentant des cycles réguliers. Pour les données financières hebdomadaires, la saisonnalité de 5 jours ouvrés est souvent capturée implicitement dans la structure autoregressive.

Le lissage exponentiel de **Holt-Winters** [2] offre une alternative robuste et non paramétrique, modélisant séparément tendance, niveau et saisonnalité. Sa version additive est particulièrement adaptée aux séries avec tendance linéaire, mais montre des limites face aux oscillateurs bornés comme le Stochastique, dont la dynamique de retour à la moyenne est incompatible avec l'extrapolation de tendance.

2.2 Machine Learning pour la finance

Les méthodes d'ensemble, notamment les **Random Forests** (Breiman, 2001) [3], capturent des interactions non-linéaires entre variables de retard (*lags*) sans hypothèse de stationnarité. Leur robustesse face aux changements de régime en fait un choix populaire en finance quantitative. L'agrégation de centaines d'arbres de décision réduit la variance tout en maintenant un biais modéré.

Les **Support Vector Regressors** (SVR) avec noyau RBF [4] introduisent une non-linéarité via projection en espace de haute dimension. La régularisation C et le paramètre d'insensibilité ε permettent un contrôle précis du compromis biais-variance, particulièrement utile sur des séries courtes où le sur-apprentissage est un risque majeur.

2.3 Deep Learning pour les séries temporelles

Les réseaux **LSTM** (Hochreiter & Schmidhuber, 1997) [5] ont révolutionné la modélisation de séries temporelles grâce à leurs portes de contrôle (input, forget, output) permettant de mémoriser des dépendances à long terme tout en filtrant le bruit à court terme. Les réseaux **GRU** (Cho et al., 2014) [6] simplifient l'architecture avec seulement deux portes (reset, update), montrant souvent de meilleures performances sur des jeux de données de taille modérée grâce à leur moindre tendance au sur-apprentissage.

Les **Transformers** (Vaswani et al., 2017) [7], basés sur un mécanisme d'auto-attention, permettent une modélisation parallèle de toute la séquence sans récurrence. Des travaux récents (Zeng et al., 2023 [8] — *Are Transformers Effective for Time Series Forecasting?*) remettent cependant en question leur supériorité sur les séries financières, montrant que des modèles linéaires simples peuvent rivaliser sur de nombreux benchmarks standardisés.

2.4 Positionnement de notre étude

La littérature actuelle souffre d'un biais important : les benchmarks sont souvent réalisés sur des fenêtres temporelles homogènes, sans distinguer les *régimes de marché*. Notre contribution principale est d'introduire une **stratification explicite par régime** (Bull, Crash, Bear, Rebound, Décennie complète) afin de mesurer la robustesse conditionnelle des modèles, une dimension méthodologique rarement traitée dans les études comparatives existantes.

Chapitre 3

Méthodologie

3.1 Pipeline expérimentale




FIGURE 3.1 – Indicateurs calculés sur AAPL — vue globale sur la période complète




FIGURE 3.2 – Indicateurs techniques calculés sur MSFT et NVDA

3.2 Données et prétraitement

Les données boursières couvrent une période de 10 ans (2015–2024) et sont disponibles à deux granularités temporelles :

- **Daily** : données quotidiennes (environ 2500 points par actif sur 10 ans)
- **Weekly** : agrégation hebdomadaire par rééchantillonnage OHLC (Open-High-Low-Close), soit environ 520 points sur 10 ans

Prétraitement appliqué :

1. Calcul des indicateurs MACD(12,26,9) et Stochastique(14,3,5) sur les prix bruts
2. Normalisation Min-Max par tranche temporelle (évite la fuite d'information inter-période)
3. Construction de fenêtres glissantes : look-back = 60 (daily), 52 (weekly)
4. Division chronologique stricte : 70% entraînement / 15% validation / 15% test
5. Horizon de prévision : **15 pas en avant**

3.3 Définition des régimes de marché

La stratification par régime est la clé de voûte méthodologique de cette étude. Cinq périodes distinctes ont été définies en fonction des conditions macro-économiques et de volatilité :

TABLE 3.1 – Définition des régimes de marché

Identifiant	Période	Caractéristiques
bull_pre_covid	2017–2020	Croissance soutenue, faible volatilité, tendance forte et stable
covid_crash	2020–2021	Crash brutal (−35% en mars 2020) suivi d’un rebond exceptionnel
bear_inflation	2022	Marché baissier prolongé, inflation élevée, corrélations rompues
ai_rebound	2023–2024	Forte hausse tirée par l’IA (NVDA +200%), volatilité spéculative
full_10y	2015–2024	Fenêtre complète, sert de baseline de référence

3.4 Matrice expérimentale

TABLE 3.2 – Dimensions de la matrice expérimentale

Dimension	Valeurs	Cardinalité
Actifs	AAPL, MSFT, NVDA	3
Granularités	Daily, Weekly	2
Régimes de marché	bull, crash, bear, rebound, full_10y	5
Total par modèle	$3 \times 2 \times 5 = 30$ configurations	
Total global	$8 \text{ modèles} \times 30 = 240$ runs	

3.5 Modèles évalués

Huit modèles sont comparés, couvrant trois familles algorithmiques :

TABLE 3.3 – Modèles évalués et hyperparamètres principaux

Famille	Modèle	Configuration
Baseline	Random Walk	Dernier point observé + bruit gaussien cumulatif (σ estimé sur l'entraînement, graine fixe)
Statistique	ARIMA	Sélection AIC ($p \leq 2$, $d = 1$, $q \leq 2$), fit par fenêtre glissante
	SARIMA	$(1, 1, 1)(1, 0, 1)_5$ fixé, fit par fenêtre glissante
	Holt-Winters	Tendance additive, lissage optimisé, fit par fenêtre glissante
Machine Learning	Random Forest	$n_{\text{est}} = 200$, sortie multi-pas directe
	SVR	Noyau RBF, $C = 1,0$, $\varepsilon = 0,1$
Deep Learning	LSTM	2 couches, hidden=128, dropout=0.2, early stopping
	GRU	2 couches, hidden=128, dropout=0.2, early stopping
	Transformer	$d_{\text{model}} = 64$, 4 têtes d'attention, 2 couches encodeur

3.6 Métriques d'évaluation

3.6.1 Métriques individuelles

Trend Accuracy (T) Proportion de pas où le modèle prédit correctement la direction (hausse ou baisse) de l'indicateur. Une valeur de 0,5 correspond au niveau du hasard.

Corrélation de Pearson (ρ) Mesure la co-variation linéaire entre la série prédite et la série réelle. Une corrélation positive indique que le modèle suit la dynamique même si les valeurs absolues s'écartent.

RMSE Racine de l'erreur quadratique moyenne, utilisée comme métrique auxiliaire pour les erreurs de magnitude.

3.6.2 Score Hackathon

Le score composite officiel de l'évaluation est :

$$S = \frac{T_{\text{MACD}} + \max(0, \rho_{\text{MACD}}) + T_{\text{Stoch}} + \max(0, \rho_{\text{Stoch}})}{4} \quad (3.1)$$

Ce score présente plusieurs propriétés importantes : (1) les corrélations négatives sont neutralisées à 0 (un modèle anti-prédictif ne pénalise pas plus qu'un modèle nul) ; (2) le score est borné en $[0, 1]$.

Chapitre 4

Résultats

Baseline de référence : la marche aléatoire. Avant d’analyser les résultats des modèles, il convient de fixer un plancher de performance. La **marche aléatoire** (*Random Walk*) — qui projette le dernier point observé en y ajoutant un bruit gaussien cumulatif calibré sur la volatilité historique — constitue le modèle le plus naïf envisageable. Sur l’ensemble de la matrice expérimentale (54 combinaisons, 3 actifs, 2 granularités, 5 régimes), la marche aléatoire obtient un score hackathon moyen de $S_{RW} = 0,263$. Ce résultat fournit le seuil naturel en dessous duquel un modèle n’apporte aucune valeur ajoutée par rapport au hasard. Nous fixons donc comme critère de performance minimal $S \geq 0,30$: tout modèle atteignant ce seuil démontre une capacité prédictive significativement supérieure à la marche aléatoire. L’ensemble des huit modèles testés dépasse ce seuil en moyenne, ce qui valide collectivement leur signal.

Cela posé, il est indispensable de poser le cadre macro : le **régime de marché** est le facteur le plus déterminant de la performance, bien avant le choix du modèle. Cette section commence donc par une lecture transversale de tous les régimes, puis zoome progressivement sur le Bull Market pré-COVID — le régime qui concentre les meilleures performances individuelles.

4.1 Analyse par régime de marché

4.1.1 Hiérarchie de prévisibilité des régimes




FIGURE 4.1 – Score hackathon moyen par modèle et régime de marché — tous actifs, daily et weekly confondus. La ligne pointillée sépare la marche aléatoire (baseline) des modèles évalués ; le seuil $S = 0,30$ est indiqué sur la barre de couleur.

En moyennant tous les modèles et indicateurs, la hiérarchie de prévisibilité est la suivante :

TABLE 4.1 – Score moyen de Trend Accuracy par régime (tous modèles confondus)

Rang	Régime	Score moyen	Interprétation
1	Bull Market (2017–2020)	0.521	Tendance forte et stable, plus prévisible
2	COVID Crash (2020–2021)	0.516	Directionnelle forte malgré la violence
3	Full 10 ans (2015–2024)	0.510	Lissage temporel masque les spécificités
4	AI Rebound (2023–2024)	0.496	Forte spéculation, indicateurs bruités
5	Bear/Inflation (2022)	0.488	Rupture des corrélations classiques

4.1.2 Variabilité inter-régimes d’un même modèle

L’une des contributions majeures de cette étude est de quantifier la **variance conditionnelle** des modèles selon le régime. Les exemples suivants illustrent l’amplitude de cette fragilité :

TABLE 4.2 – Variabilité de la Trend Accuracy selon le régime (indicateur MACD, Weekly)

Actif	Modèle	Meilleure période	Score max	Pire période	Écart
NVDA	ARIMA	Bull Market	0.914	AI Rebound	40.3%
AAPL	SVR	Bull Market	0.847	COVID Crash	50.2%
MSFT	Random Forest	Bear/Inflation	0.693	COVID Crash	7.0%

On note que le Random Forest sur MSFT est de loin le modèle le plus stable, avec un écart de seulement 7% entre sa meilleure et sa pire période — contre 50% pour le SVR sur AAPL. Cette stabilité remarquable explique pourquoi Random Forest domine le classement en robustesse globale malgré l'absence de pic de performance exceptionnel.

L'ARIMA illustre l'extrême opposé : sur certaines configurations du Stochastique, il descend à **0% de Trend Accuracy**, ce qui signifie qu'il prédit systématiquement la mauvaise direction. Ce phénomène correspond à un modèle qui capte une dynamique de tendance passée mais la projette dans un marché dont le régime a changé.

4.1.3 Argument pour la stratification par régime

L'utilisation du `full_10y` comme unique période de test, bien qu'intuitive, présente deux risques méthodologiques majeurs :

1. **Biais de survie** : Tester uniquement sur le Bull Market surestime massivement la robustesse. Un modèle avec $S = 0,62$ en Bull peut chuter à $S = 0,20$ en Bear/Inflation.
2. **Risque de ruine** : Déployer en production un modèle validé uniquement sur un marché haussier expose à des pertes catastrophiques lors du prochain cycle baissier ou de choc exogène.

4.2 Vue d'ensemble des scores hackathon

Cette vision macro posée, le classement des performances individuelles confirme la domination du Bull Market pré-COVID : les configurations les plus performantes proviennent majoritairement de ce seul régime.

4.2.1 Configurations dépassant le seuil $S \geq 0,30$

Sur l'ensemble des combinaisons testées, **56% des configurations** franchissent le seuil $S \geq 0,30$. Les moyennes par modèle s'échelonnent de 0,288 (ARIMA, seul modèle dont la moyenne reste sous le seuil) à 0,358 (Random Forest). Les configurations de tête — celles dépassant nettement $S \geq 0,55$ — appartiennent toutes à la granularité hebdomadaire (*weekly*), confirmant la supériorité de cette granularité.

TABLE 4.3 – Top configurations par score hackathon — classées par score décroissant

Actif	Période	Modèle	T_{MACD}	ρ_{MACD}	T_{Stoch}	ρ_{Stoch}	S
NVDA	bull_pre_covid	SARIMA	82.8%	0.654	60.4%	0.411	0.6246
AAPL	bull_pre_covid	SVR	84.7%	0.937	55.4%	0.097	0.6092
NVDA	bull_pre_covid	ARIMA	91.4%	0.809	63.7%	0.000	0.5902
NVDA	bull_pre_covid	HoltWinters	91.4%	0.854	50.5%	0.012	0.5716
NVDA	covid_crash	GRU	63.1%	0.807	57.1%	0.228	0.5596
NVDA	covid_crash	SARIMA	58.3%	0.386	66.0%	0.578	0.5521

Le MACD est l'indicateur le mieux prédit dans les configurations de tête : les corrélations dépassent souvent 0,80 avec des trend accuracies de 85–91%. Le Stochastique constitue le facteur limitant, sa nature bruitée et oscillante empêchant les modèles de dépasser 0,40–0,50 de corrélation.

4.2.2 Classement global par robustesse moyenne

TABLE 4.4 – Classement global des modèles par score hackathon moyen (toutes configurations)

Rang	Modèle	Score moyen	Famille
1	Random Forest	0.358	Machine Learning
2	SVR	0.351	Machine Learning
3	Transformer	0.338	Deep Learning
4	SARIMA	0.337	Statistique
5	GRU	0.334	Deep Learning
6	LSTM	0.325	Deep Learning
7	Holt-Winters	0.309	Statistique
8	ARIMA	0.287	Statistique




FIGURE 4.2 – Classement global des modèles par score hackathon moyen

4.2.3 Le paradoxe robustesse/performance de pointe

Ce classement révèle une tension fondamentale entre *performance de pointe* et *robustesse moyenne* :

- Les modèles statistiques (ARIMA, SARIMA, Holt-Winters) **monopolisent les 4 premières places du top individuel** (configurations $S \geq 0,55$), mais terminent **derniers en robustesse globale** — ARIMA étant le seul modèle dont la moyenne (0,288) reste sous le seuil de 0,30.
- Le Random Forest et le SVR **n’ont aucune configuration individuelle au-dessus de 0,55**, mais finissent premiers en robustesse moyenne, bien au-dessus du seuil de 0,30.

Ce phénomène s’explique par la variance conditionnelle au régime : les modèles statistiques s’effondrent hors de leur zone de confort (marchés volatils, données insuffisantes), tandis que les modèles ML maintiennent des performances médiocres mais stables sur l’ensemble des régimes.

4.3 Focus : Bull Market pré-COVID (2017–2020)

Le Bull Market pré-COVID étant le régime concentrant les meilleures performances — et celui sur lequel les recommandations de déploiement seront les plus actionnables — les sections suivantes lui consacrent une analyse complète : comportement par actif, impact de la granularité, comparaison des familles algorithmiques et visualisations.

4.3.1 Analyse par actif




FIGURE 4.3 – Heatmaps de Trend Accuracy par modèle et configuration




FIGURE 4.4 – Heatmaps de corrélation de Pearson par modèle et configuration

Apple (AAPL)

Apple présente un profil mixte : excellent rendement avec les bons modèles en Bull Market, mais forte sensibilité aux changements de régime. Le SVR domine presque toutes les métriques en Bull Market hebdomadaire :

- T_{MACD} : SVR Weekly = **0.8476**
- T_{Stoch} : SVR Weekly = **0.5549**
- ρ_{MACD} : SVR Weekly = **0.9374** (corrélation quasi-parfaite)
- ρ_{Stoch} : LSTM Weekly = **0.1754**

Un résultat frappant est que l'ARIMA sur AAPL (Weekly) a produit simultanément sa meilleure et sa pire performance : une corrélation MACD de -0.9564 sur la même période Bull Market, soit une prédiction quasi-parfaitement *inversée*. Ce phénomène illustre la fragilité des modèles linéaires dans certaines configurations : ARIMA capte une dynamique

réelle, mais dans la mauvaise direction lorsque la série présente des inflexions rapides non prises en compte dans l'ordre de différenciation.

Nvidia (NVDA)

NVDA est l'actif le plus représenté dans le Top 6 et le plus facile à modéliser en tendance MACD (0,610 de précision moyenne en Bull Market). Sa forte directionnalité haussière est particulièrement bien capturée par les modèles statistiques :

- Les modèles ARIMA, SARIMA et Holt-Winters **dominent tous les indicateurs** en Bull Market hebdomadaire.
- ARIMA atteint 91,4% de Trend Accuracy MACD — la valeur la plus haute de toute l'étude.
- Holt-Winters atteint $\rho_{\text{MACD}} = 0,854$, le deuxième meilleur score de corrélation MACD toutes configurations confondues.
- En COVID Crash, NVDA reste le seul actif permettant d'atteindre $S \geq 0,55$ (GRU et SARIMA), confirmant que sa forte directionnalité de rebond reste exploitable même en période de crise.

Microsoft (MSFT)

MSFT présente le profil le plus régulier et le plus stable. Sa croissance monotone le rend globalement plus facile à modéliser en moyenne ($\bar{S} = 0,334$), mais génère peu de pics de performance exceptionnelle :

- Contrairement aux autres actifs, le meilleur modèle pour le MACD est **SVR Daily** ($T = 0,5849$), suggérant que la dynamique MACD de MSFT opère à une échelle de temps plus courte.
- Le Stochastique est mieux capté en weekly par Random Forest ($T_{\text{Stoch}} = 0,6264$).
- Le Random Forest sur MSFT est le modèle le plus stable de toute l'étude (écart de seulement 7% entre meilleure et pire période).
- La corrélation $\rho_{\text{Stoch}} = 0,6430$ du SVR Weekly est la meilleure corrélation Stochastique de l'ensemble de l'étude.

4.3.2 Analyse par granularité temporelle

TABLE 4.5 – Comparaison Daily vs Weekly par métrique (Bull Market, tous modèles, tous actifs)

Métrique	Weekly	Daily
T_{MACD}	0.5688	0.5088
T_{Stoch}	0.5165	0.4896
ρ_{MACD}	0.1524	0.0081
ρ_{Stoch}	-0.0298	0.0456

Le résultat est univoque : **le weekly domine le daily** sur presque toutes les métriques. Cela s’explique par la réduction du bruit microstructurel, la meilleure stationnarité locale des indicateurs agrégés, et la perte de données pour les modèles DL sur les périodes courtes (moins de 52 points après division pour `bear_inflation`).

La seule exception concerne la corrélation du Stochastique, où le daily s’en tire légèrement mieux — mais les deux valeurs restent proches de zéro, indiquant que le Stochastique est difficile à prédire quelle que soit la granularité.

4.3.3 Comparaison par famille algorithmique

TABLE 4.6 – Performance moyenne par famille algorithmique en Bull Market — granularité Weekly

Famille	T_{MACD}	T_{Stoch}	ρ_{MACD}	ρ_{Stoch}
Statistique (ARIMA/SARIMA/HW)	0.573	0.510	0.132	0.020
Machine Learning (RF/SVR)	0.559	0.534	0.185	0.100
Deep Learning (LSTM/GRU/Transf.)	0.490	0.480	-0.041	-0.029

TABLE 4.7 – Top 3 par métrique en Bull Market — granularité Weekly, tous actifs

Métrique	Rang	Modèle	Score moyen
T_{MACD}	1	SVR	0.619
	2	Holt-Winters	0.605
	3	SARIMA	0.589
T_{Stoch}	1	Random Forest	0.543
	2	SVR	0.524
	3	SARIMA	0.518
ρ_{MACD}	1	SVR	0.292
	2	Holt-Winters	0.190
	3	SARIMA	0.187
ρ_{Stoch}	1	SVR	0.130
	2	SARIMA	0.072
	3	Random Forest	0.070

4.3.4 Heatmaps et visualisations par actif






FIGURE 4.5 – Heatmaps de performances pour NVDA en granularité Weekly



(a) AAPL Weekly — MACD




(b) MSFT Weekly — MACD

FIGURE 4.6 – Heatmaps MACD Weekly pour AAPL et MSFT



(a) NVDA Daily — MACD



(b) NVDA Daily — Stochastique

FIGURE 4.7 – Comparaison Daily vs Weekly pour NVDA — illustration de la dégradation en Daily

Chapitre 5

Discussion

5.1 Pourquoi le MACD est-il plus facile à prédire que le Stochastique ?

Le MACD est la différence de deux moyennes mobiles exponentielles — une transformation lissante qui atténue le bruit haute fréquence et préserve les tendances de moyen terme. Son comportement est proche d’une série non-stationnaire à tendance locale, ce qui favorise les modèles capturant des momentum persistants (ARIMA, SARIMA, Holt-Winters en Bull Market).

Le Stochastique, en revanche, est un oscillateur **borné entre 0 et 100**. Sa dynamique de retour à la moyenne, ses fréquentes inversions entre zones de surachat (> 80) et de survente (< 20), et sa forte sensibilité aux gaps de prix le rendent intrinsèquement plus difficile à modéliser. Aucun modèle ne dépasse 0,65 de corrélation de Pearson sur le Stochastique dans notre étude. Les modèles de tendance comme Holt-Winters produisent même des corrélations négatives systématiques, prouvant que l’hypothèse de tendance est fondamentalement incompatible avec la dynamique d’un oscillateur.





FIGURE 5.1 – Comparaison des corrélations de Pearson entre MACD et Stochastique — tous modèles et configurations. L’écart structurel entre les deux indicateurs est visible sur l’ensemble de la matrice.


5.2 Pourquoi le Bull Market pré-COVID est-il le régime le plus prévisible ?

Trois caractéristiques structurelles expliquent cette prévisibilité supérieure :

1. **Tendance forte et monotone** : La croissance quasi-continue de 2017 à 2020 crée une série dont la direction future est fortement auto-corrélée avec la direction passée — exactement ce que capturent les modèles AR.
2. **Faible volatilité** : Les indicateurs techniques sont moins bruités, augmentant le ratio signal/bruit pour tous les modèles.
3. **Régularité saisonnière** : Les cycles earnings trimestriels créent des patterns réguliers capturés par SARIMA et les features de retard de Random Forest.



(a) Bull Market pré-COVID — NVDA MACD



(b) AI Rebound (2023–2024) — NVDA MACD

FIGURE 5.2 – Impact du régime sur la qualité de prédiction MACD (NVDA Weekly) : la tendance forte et monotone du Bull Market contraste avec la volatilité spéculative de l’AI Rebound.

5.3 Pourquoi le Deep Learning sous-performe sur séries courtes ?

La contre-performance du Deep Learning est l’un des résultats les plus instructifs de l’étude. Trois mécanismes concourent à expliquer ces résultats :

Manque de données Les périodes de 3–5 ans ne fournissent que 300–500 points en granularité daily et 50–80 en weekly. Des architectures LSTM à 128 unités cachées ont des centaines de milliers de paramètres, conduisant à un surapprentissage quasi-systématique.

Absence de préentraînement Un Transformer financier moderne serait préentraîné sur des années de données multi-actifs. Ici, les poids sont initialisés aléatoirement, ce qui pénalise structurellement l’architecture par rapport aux modèles statistiques qui s’adaptent localement.

Inadéquation indicateur-architecture L’auto-attention du Transformer cherche des relations globales dans la séquence — pertinent pour le traitement du langage, moins évident pour un oscillateur borné dont la dynamique est essentiellement locale et de courte portée.

5.4 Implications pour la finance quantitative

5.4.1 Il n’existe pas de modèle universellement optimal

Cette étude démontre empiriquement qu’aucun modèle n’est universellement optimal pour la prédiction d’indicateurs techniques. Le choix optimal dépend de trois facteurs en interaction : *régime de marché*, *actif cible*, et *granularité temporelle*. Un modèle déployé en production sans adaptation dynamique de ces trois dimensions est condamné à la médiocrité ou, pire, à la perte de capital.




FIGURE 5.3 – Heatmaps globales de Trend Accuracy (tous actifs, toutes périodes) : l’absence de bloc uniformément coloré confirme qu’aucun modèle ne domine sur l’ensemble de la matrice.

5.4.2 La granularité comme filtre de bruit

Le passage du daily au weekly constitue une forme de filtrage passe-bas qui améliore presque uniformément toutes les métriques. Cela suggère que la valeur prédictive des indicateurs techniques réside dans les dynamiques de moyen terme (2–4 semaines) plutôt que dans les fluctuations journalières, qui relèvent davantage du bruit microstructurel.

Chapitre 6

Limites, Perspectives et Conclusion

6.1 Limites de l'étude

1. **Univers d'actifs limité** : Seuls 3 actifs technologiques américains sont couverts. La généralisation à d'autres secteurs (commodities, obligataires, cryptos) n'est pas établie.
2. **Dépendance à la définition des régimes** : les bornes des périodes (ex. 2022 = Bear) sont choisies manuellement et pourraient biaiser les conclusions si on les déplaçait de quelques mois.
3. **Hyperparamètres fixes** : Les architectures DL n'ont pas fait l'objet de recherche systématique d'hyperparamètres (grid search, Bayesian optimization), ce qui pénalise probablement cette famille.
4. **Horizon unique** : Seul l'horizon $H = 15$ est testé. Des horizons plus courts ($H = 5$) pourraient favoriser différemment les modèles statistiques.

6.2 Pistes de recherche futures

- **Préentraînement multi-actifs** du Transformer sur un large corpus d'actions, suivi d'un fine-tuning par régime de marché.
- **Modèles hybrides** ARIMA-GARCH pour capturer simultanément tendance et variance conditionnelle des indicateurs.
- **Extension à d'autres classes d'actifs** (cryptomonnaies, matières premières, obligataire) afin de tester la généralisation des conclusions au-delà des actions technologiques américaines.
- **Modèles adaptés aux séries courtes** : exploration d'architectures comme N-BEATS ou Prophet, conçues pour fonctionner avec des jeux de données de taille limitée, afin de pallier les difficultés structurelles du Deep Learning classique dans ce contexte.
- **Intégration du sentiment de marché** via l'analyse NLP de sources comme Twitter/X ou Reddit, pour enrichir les features exogènes et capturer des signaux comportementaux non reflétés dans les prix historiques.

6.3 Conclusion

Cette étude livre cinq enseignements majeurs pour la prédiction d'indicateurs techniques financiers :

1. **Le régime de marché prime sur le modèle.** L'écart de performance entre le Bull Market et le Bear/Inflation dépasse l'écart entre le meilleur et le pire modèle sur une même période. Aucun algorithme ne peut compenser un contexte de marché fondamentalement défavorable.
2. **La granularité hebdomadaire est systématiquement supérieure.** Elle filtre le bruit microstructurel et améliore toutes les métriques de prédiction pour les indicateurs de moyen terme.
3. **Paradoxe robustesse/performance de pointe.** Les modèles statistiques génèrent les meilleures configurations individuelles (jusqu'à $S = 0,62$) mais s'effondrent hors de leur zone de confort. Les modèles ML (Random Forest, SVR) sont moins brillants mais plus fiables en production.
4. **Le Deep Learning déçoit sur séries courtes.** Sans préentraînement et avec des jeux de données de quelques centaines de points, LSTM, GRU et Transformer sont inférieurs à SVR et Random Forest.
5. **Le MACD est plus prédictible que le Stochastique.** Sa dynamique de tendance lissée est plus facile à modéliser qu'un oscillateur borné à haute réversion. Le Stochastique reste la principale limite structurelle à l'obtention de scores élevés ($S \geq 0,55$).

La contribution méthodologique principale de ce travail est l'établissement d'une **grille d'évaluation stratifiée par régime de marché** comme standard minimum pour l'évaluation rigoureuse des modèles de prédiction financière. Un modèle évalué sur une seule période homogène ne peut pas prétendre à une validité robuste en conditions réelles.

Chapitre 7

Annexes

.1 Glossaire des termes techniques

MACD Moving Average Convergence Divergence — différence entre deux EMA utilisée pour détecter les changements de tendance.

Stochastique Oscillateur borné $[0, 100]$ mesurant la position relative du prix dans son range récent, indicateur de surachat/survente.

Trend Accuracy Proportion de prédictions où la direction (hausse/baisse) est correctement anticipée. Baseline aléatoire = 0,5.

Corrélation de Pearson ρ Mesure linéaire de la co-variation entre série prédite et réelle, comprise en $[-1, 1]$.

Régime de marché Période homogène définie par ses caractéristiques macro-économiques et de volatilité (Bull, Bear, Crash, Rebound).

Look-back Nombre de pas de temps passés utilisés comme features d'entrée du modèle.

Horizon Nombre de pas de temps futurs à prédire simultanément (ici $H = 15$).

EMA Moyenne Mobile Exponentielle, donnant plus de poids aux observations récentes.

RMSE Root Mean Squared Error — métrique d'erreur de prédiction absolue.

Bull Market Marché haussier caractérisé par une tendance ascendante prolongée et une faible volatilité.

Bear Market Marché baissier caractérisé par une baisse prolongée des prix, souvent accompagnée d'une rupture des corrélations habituelles.

.2 Scores hackathon complets (toutes configurations)

TABLE 1 – Scores hackathon S par configuration. **Gras** : $S \geq 0,30$. Abréviations — TF : D=Daily, W=Weekly ; modèles : RW=RandomWalk, HW=Holt-Winters, RF=RandomForest, Transf.=Transformer.

Actif	TF	Période	RW	ARIMA	SARIMA	HW	RF	SVR	LSTM	GRU	Transf.
AAPL	D	Bull 17–20	0.248	0.168	0.299	0.294	0.265	0.259	0.261	0.262	0.278
AAPL	D	COVID 20–21	0.256	0.400	0.334	0.313	0.365	0.351	0.365	0.410	0.431
AAPL	D	Bear 2022	0.256	0.280	0.348	0.236	0.239	0.417	0.294	0.250	0.327
AAPL	D	AI 23–24	0.242	0.327	0.319	0.251	0.347	0.372	0.352	0.447	0.320
AAPL	D	Full 10Y	0.248	0.319	0.259	0.241	0.395	0.285	0.449	0.451	0.415
AAPL	W	Bull 17–20	0.224	0.136	0.459	0.505	0.254	0.609	0.350	0.238	0.226
AAPL	W	COVID 20–21	0.305	0.222	0.269	0.345	0.230	0.207	0.250	0.347	0.210
AAPL	W	AI 23–24	0.330	0.113	0.233	0.313	0.400	0.283	0.290	0.244	0.311
AAPL	W	Full 10Y	0.249	0.345	0.276	0.236	0.465	0.453	0.472	0.526	0.491
MSFT	D	Bull 17–20	0.243	0.267	0.292	0.242	0.265	0.339	0.252	0.243	0.260
MSFT	D	COVID 20–21	0.305	0.472	0.381	0.366	0.500	0.415	0.255	0.263	0.472
MSFT	D	Bear 2022	0.242	0.211	0.399	0.315	0.467	0.363	0.253	0.362	0.280
MSFT	D	AI 23–24	0.270	0.441	0.263	0.245	0.445	0.309	0.273	0.377	0.424
MSFT	D	Full 10Y	0.261	0.346	0.312	0.271	0.436	0.359	0.483	0.489	0.437
MSFT	W	Bull 17–20	0.249	0.313	0.202	0.201	0.406	0.471	0.309	0.258	0.257
MSFT	W	COVID 20–21	0.246	0.250	0.387	0.332	0.416	0.302	0.348	0.330	0.410
MSFT	W	AI 23–24	0.320	0.357	0.219	0.390	0.407	0.387	0.310	0.246	0.319
MSFT	W	Full 10Y	0.249	0.157	0.311	0.267	0.350	0.296	0.337	0.291	0.374
NVDA	D	Bull 17–20	0.249	0.324	0.319	0.242	0.301	0.292	0.318	0.364	0.350
NVDA	D	COVID 20–21	0.295	0.261	0.427	0.371	0.389	0.291	0.350	0.365	0.457
NVDA	D	Bear 2022	0.247	0.387	0.353	0.228	0.348	0.309	0.230	0.289	0.242
NVDA	D	AI 23–24	0.269	0.226	0.405	0.344	0.279	0.251	0.254	0.252	0.331
NVDA	D	Full 10Y	0.252	0.209	0.332	0.293	0.385	0.325	0.366	0.409	0.353
NVDA	W	Bull 17–20	0.248	0.590	0.625	0.572	0.463	0.455	0.359	0.235	0.263
NVDA	W	COVID 20–21	0.265	0.269	0.552	0.443	0.351	0.494	0.466	0.560	0.289
NVDA	W	AI 23–24	0.270	0.240	0.255	0.257	0.238	0.355	0.285	0.278	0.289
NVDA	W	Full 10Y	0.265	0.139	0.282	0.247	0.263	0.247	0.258	0.255	0.313

Bibliographie

- [1] G. E. P. Box, G. M. Jenkins, G. C. Reinsel et G. M. Ljung, *Time Series Analysis : Forecasting and Control*, 5^e éd. Wiley, 2015. https://repo.darmajaya.ac.id/4781/1/Time%20Series%20Analysis_%20Forecasting%20and%20Control%20%28%20PDFDrive%20%29.pdf
- [2] R. J. Hyndman et G. Athanasopoulos, *Forecasting : Principles and Practice*. OTexts, 2018. <https://robjhyndman.com/uwafiles/fpp-notes.pdf>
- [3] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001. <https://link.springer.com/article/10.1023/A:1010933404324>
- [4] A. J. Smola et B. Schölkopf, “A Tutorial on Support Vector Regression,” *Statistics and Computing*, vol. 14, pp. 199–222, 2004. <https://alex.smola.org/papers/2004/SmoSch04.pdf>
- [5] S. Hochreiter et J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, n^o 8, pp. 1735–1780, 1997. <https://www.bioinf.jku.at/publications/older/2604.pdf>
- [6] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk et Y. Bengio, “Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation,” in *Proc. EMNLP 2014*, pp. 1724–1734. <https://aclanthology.org/D14-1179.pdf>
- [7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser et I. Polosukhin, “Attention Is All You Need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf
- [8] A. Zeng, M. Chen, L. Zhang et Q. Xu, “Are Transformers Effective for Time Series Forecasting?” in *Proc. AAAI Conference on Artificial Intelligence*, vol. 37, 2023. <https://ojs.aaai.org/index.php/AAAI/article/view/26317/26089>